

מסמך אפיון מערכת (System Specification)

פרויקט: MarketPulse BI - מערכת Data & Analytics לשוק ההון

1. מטרת המערכת (System Purpose)

מערכת MarketPulse BI היא פלטפורמת מודיעין פיננסי אוטומטית מקצה לקצה (End-to-End). מטרתה אינה מסתכמת רק בהצגת דאשבורד, אלא בהדגמת מחזור חיים מלא של פרויקט Data & BI: החל מאיסוף נתונים (Data Ingestion), דרך הנדסת נתונים ואיכות נתונים (Data Engineering & DQ), שילוב מודל שפה (NLP), עיצוב מסד נתונים ומידול (Data Modeling), אריזה במכולות ותזמור (Containerization & Kubernetes), ועד לשכבת האנליטיקה והניטור (BI & Monitoring). המערכת שואבת נתונים כמותיים ואיכותניים, שומרת עותק גולמי (Raw Data), מעבדת אותם ושומרת במודל נתונים רב-ממדי (Star Schema) ב-PostgreSQL, המהווה תשתית לשכבת הבינה העסקית ב-Power BI.

2. משתמשים ובעלי עניין (Users & Stakeholders)

- Data Analyst / BI Developer:** צרכן שכבת ה-Data Warehouse, המשתמש במודל הנתונים המעובד (Curated Data) ליצירת מדדי DAX ודאשבורדים אנליטיים.
- Data Engineer / System Admin:** הגורם האחראי על תחזוקת הארכיטקטורה, ניטור הלוגים התפעוליים (Operational Logging), ניהול שגיאות ב-Pipeline, ווידוא איכות הנתונים (Data Quality).
- End User (אנליסט פיננסי):** משתמש הקצה אשר צורך את התובנות החזותיות דרך דאשבורדים, במטרה לקבל החלטות מבוססות-נתונים (Data-driven insights) על תנועות מחיר וסנטימנט.

3. גבולות גזרה ותיחום (Scope)

מה נכלל בפרויקט (In Scope):

- פיתוח Containerized Data Pipeline מתוזמר על ידי Kubernetes.
- שמירת שכבת נתונים גולמית (Raw Data) לצורכי Debugging ו-Replay.
- סינון, טרנספורמציה ובקרת איכות (Data Quality).
- סיווג סנטימנט לכותרות פיננסיות באמצעות מודל FinBERT.
- עיצוב מסד נתונים יחסי (PostgreSQL) בגישת Star Schema עם טבלאות ממדים ועובדות, כולל טבלת ברמת הכתבה (Article-Level).
- פיתוח שכבה אנליטית (Power BI) ודאשבורד לניטור תקינות ה-Pipeline.

מה מחוץ לפרויקט (Out of Scope):

- אימון מחדש (Fine-tuning) של מודל ה-NLP.
- מסחר אלגוריתמי או הפעלת פעולות מסחר בפועל.
- מערכות עיבוד נתונים בזמן אמת (Real-Time Streaming). התהליך מבוסס על אצוות (Batch Processing).
- הוספת שירותי ענן חיצוניים מורכבים או טכנולוגיות Big Data (כגון Spark, Kafka) שאינן נדרשות להיקף הנתונים הנוכחי.

4. ארכיטקטורת המערכת (System Architecture)

המערכת בנויה כ-**Containerized Data Pipeline orchestrated by Kubernetes**, המדמה פרקטיקות נבחרות מסביבות ייצור (simulates selected production-oriented practices). הקלאסטר המקומי (Minikube / Docker Desktop) כולל שני עמודי תווך עיקריים:

1. **Python Data Pipeline / AI Workload**: קוד השאיבה, העיבוד וה-NLP הארוז במכולה (Docker)

(Container).

2. **PostgreSQL StatefulSet**: מסד הנתונים השומר את הנתונים, מחובר ל-Persistent Volume כדי

להבטיח את שרידות המידע גם בעת קריסת הפוד.

היררכיית התזמור ב-Kubernetes:

- **CronJob**: אחראי על תזמון הריצה (למשל, בכל יום לאחר סגירת המסחר).
- **Job**: מייצג הפעלה (Execution) חד-פעמית של המשימה שנוצרה על ידי ה-CronJob.
- **Pod**: סביבת הריצה של המכולה שנוצרה על ידי ה-Job.
- **Python Container**: מריץ בפועל את קוד ה-ETL ואת מודל ה-FinBERT.

5. פירוט זרימת הנתונים ב-Pipeline (Detailed Pipeline)

(Flow)

התהליך רץ בצורה טורית ומבוקרת:

1. **Extract**: שאיבת נתוני מסחר (yfinance) וכותרות חדשות (RSS/APIs).
2. **Raw Storage**: שמירת הנתונים הגולמיים כפי שהתקבלו במבנה טבלאי פשוט או קבצים ב-Volume מקומי. מטרת שכבה זו היא לאפשר Debugging והרצה חוזרת (Replay) ללא תלות במקור החיצוני.
3. **Validation**: בדיקות תקינות בסיסיות (טיפוסים, ערכי חובה).
4. **Transformation**: המרת תאריכים, חישוב תשואה יומית, ניקוי טקסטים מיותרות.
5. **Sentiment Analysis**: העברת הכותרות דרך מודל FinBERT לקבלת סיווג וציון.
6. **Aggregation**: קיבוץ הנתונים (למשל, ממוצע סנטימנט יומי ברמת נכס).
7. **(Load) Idempotency**: טעינת הנתונים למסד הנתונים PostgreSQL (טבלאות ה-Analytical/Curated) תוך שימוש במנגנון Upsert למניעת כפילויות.
8. **Data Quality Checks**: הפעלת חוקים עסקיים ואנליטיים על הנתונים המעובדים ותיעוד התוצאות.
9. **Logging / Monitoring**: כתיבת לוגים תפעוליים על ביצועי ה-Pipeline (זמנים, סטטוסים).
10. **Power BI**: רענון מודל הנתונים על בסיס ה-Star Schema והצגת הנתונים למשתמש.

6. מודל הנתונים ורזולוציה (Data Model & Grain)

הנתונים נשמרים בגישת Star Schema להבטחת ביצועים אנליטיים.

- **FactDailyPrice Grain**: שורה אחת לכל נכס בכל יום מסחר (One row per asset per trading day).
- **FactSentiment Grain**: שורה אחת לכל נכס בכל יום (One row per asset per day), המכילה אגרגציה של כל כתבות החדשות מאותו יום.
- **NewsArticles Grain**: שורה אחת לכל כתבה בודדת (One row per specific article), משמשת כטבלת Raw/Processed לטובת עקיבות (Traceability).

7. מילון נתונים (Data Dictionary)

DimAsset (טבלת מטא-דאטה נכסים)

Column	Data Type	Description	Nullable	Key
AssetKey	Integer	מזהה ייחודי פנימי	No	PK
Ticker	VARCHAR(10)	סימול הנכס (למשל AAPL)	No	Unique
CompanyName	VARCHAR(100)	שם החברה או התעודה	No	
Sector	VARCHAR(50)	מגזר פעילות	Yes	

DimDate (טבלת תאריכים)

Key	Nullable	Description	Data Type	Column
PK	No	תאריך בפורמט YYYYMMDD	Integer	DateKey
	No	התאריך המלא	Date	Date
	No	אינדיקטור יום מסחר פעיל	Boolean	IsTradingDay

FactDailyPrice (טבלת עובדות מסחר)

Key	Nullable	Description	Data Type	Column
PK/FK	No	קישור לנכס	Integer	AssetKey
PK/FK	No	קישור לתאריך	Integer	DateKey
	No	שער סגירה מתוקן	Float	Close
	No	נפח מסחר	BigInt	Volume

(Idempotency: מפתח ייחודי משולב AssetKey + DateKey)

NewsArticles (טבלת מעקב כתבות - Traceability)

Key	Nullable	Description	Data Type	Column
PK	No	Hash של ה-URL	(VARCHAR(64	ArticleID

Key	Nullable	Description	Data Type	Column
		או מזהה ייחודי מה-RSS		
FK	No	קישור לנכס המוזכר בכתבה	Integer	AssetKey
	No	זמן פרסום הכתבה	DateTime	PublishedAt
	No	כותרת הכתבה (Raw text)	Text	Title
	Yes	Positive / Negative / Neutral מתוך FinBERT	(VARCHAR(15	SentimentCategory
	Yes	ציון סנטימנט רציף / ביטחון	Float	SentimentScore

(Idempotency: מפתח ייחודי ArticleID)

FactSentiment (טבלת עובדות סנטימנט מקובץ)

Key	Nullable	Description	Data Type	Column
PK/FK	No	קישור לנכס	Integer	AssetKey

Key	Nullable	Description	Data Type	Column
PK/FK	No	קישור לתאריך	Integer	DateKey
	No	כמות הכתבות שנסרקו לאותו נכס ביום זה	Integer	ArticleCount
	No	כמות כתבות חיוביות	Integer	PositiveCount
	No	כמות כתבות שליליות	Integer	NegativeCount
	No	ציון סנטימנט ממוצע משוקלל לאותו יום	Float	AvgSentimentScore

(Idempotency: מפתח ייחודי משולב DateKey + AssetKey)

(PipelineExecutionLog (Operational Logging

Key	Nullable	Description	Data Type	Column
PK	No	מזהה ייחודי של Pipeline-ה	UUID	RunID
PK	No	שם השלב Extract,)	(VARCHAR(50	PipelineStage

Key	Nullable	Description	Data Type	Column
		Transform, (Load, AI		
	No	תחילת הריצה של השלב	DateTime	StartTime
	Yes	סיום הריצה של השלב	DateTime	EndTime
	No	Success / Failed / Running	(VARCHAR(20	Status
	Yes	מספר הרשומות שטופלו בשלב	Integer	RecordsProces sed
	Yes	הודעת השגיאה במידה והשלב נכשל	Text	ErrorMessage

(DataQualityResults (Data Quality Monitoring

Key	Nullable	Description	Data Type	Column
PK	No	מזהה ייחודי לבדיקה	UUID	CheckID

Key	Nullable	Description	Data Type	Column
FK	No	מקושר לריצת ה-Pipeline	UUID	RunID
	No	סוג הבדיקה (MissingTicker, (NullPrice	(VARCHAR(50	CheckType
	No	True אם הבדיקה עברה, False אם נכשלה	Boolean	Passed
	Yes	כמות הרשומות שנכשלו בבדיקה זו	Integer	FailedRecords
	Yes	פירוט נוסף (למשל: רשימת הטיקרים שחסרים)	Text	Details

8. בקרת איכות נתונים (Data Quality)

התהליך מבצע בדיקות Data Quality. כל חריגה מתועדת בטבלת DataQualityResults.

- **Missing Ticker**: בדיקה אם התקבל טיקר שלא קיים ב-DimAsset. פעולה: הרשומה מושמטת (Rejected), מתועדת שגיאה.
- **Missing Date**: רשומות ללא תאריך חוקי. פעולה: מושמטת.
- **Missing Closing Price**: ימי מסחר ללא שער סגירה. פעולה: מושמטת, אירוע מתועד כ-Warning.

(ייתכן יום פגרה).

- **Duplicate Records / Duplicate News**: כותרות זהות לחלוטין או רשומות כפולות לאותו יום. פעולה: הסרת כפילויות (Deduplication) ושמירת עותק אחד.
- **Invalid Numerical Values**: מחירים שליליים או ווליום שלילי. פעולה: מושמטת (Rejected).
- **Invalid/Empty News Headlines**: כותרת ריקה או תווים לא קריאים. פעולה: מושמטת לפני כניסה למודל.
- **Missing Sentiment Result**: כתבה שלא עברה בהצלחה את ה-NLP. פעולה: מסומנת (Flagged) ללא ציון סנטימנט, אך נשמרת ב-NewsArticles.

9. יישום למידת מכונה (AI / NLP Implementation)

FinBERT הוא מודל שפה מאומן מראש (Pretrained language model), המותאם ספציפית לסיווג סנטימנט של טקסטים פיננסיים.

- **קלט (Input)**: כותרת חדשות פיננסית.
 - **פלט (Output)**: קטגוריית סנטימנט (Positive, Negative, Neutral) וציון ודאות (Confidence Score).
- המודל אינו מתיימר להחליף ניתוח אנושי מלא, אלא להעניק בסיס אוטומטי ואובייקטיבי לסיווג כמויות גדולות של טקסט, שעובר אגרגציה ברמת ה-Asset והתאריך.

10. טיפול בשגיאות ושרידות (Error Handling)

ניהול שגיאות הוא קריטי לרציפות ה-Pipeline:

- **API Rate Limit / API Unavailable**:
 - **זיהוי**: קוד שגיאה 429 או Timeouts ממקורות כמו yfinance.
 - **טיפול**: שימוש ב-Exponential Backoff ו-Retries (עד 3 פעמים).
 - **המשך ריצה**: אם נכשל סופית עבור טיקר מסוים, מתעד לוג, מדלג לטיקר הבא. התהליך ממשיך.
- **FinBERT Processing Failure**

- **זיהוי:** שגיאה בהרצת הטקסט במודל (למשל טקסט ארוך מדי או שגיאת זיכרון).
- **טיפול:** חיתוך הטקסט לגודל המותר או תפיסת החריגה (Exception).
- **המשך ריצה:** הכתבה מתועדת כנכשלת ב-Data Quality, ה-Pipeline ממשיך.

● PostgreSQL Unavailable:

- **זיהוי:** חוסר יכולת לפתוח Connection למסד הנתונים.
- **טיפול:** המתנה ארוכה יותר לניסיון התחברות חוזר.
- **המשך ריצה:** אם נכשל לחלוטין, ה-Pipeline עוצר (Fatal Error), סטטוס Failed נרשם (אם ניתן), והתראה נוצרת ברמת הקוברנטים.

● Kubernetes Pod Failure (OOM / Node Issue):

- **זיהוי:** הפוד קורס (CrashLoopBackOff).
- **טיפול:** קוברנטים ינסה לאתחל את הפוד של ה-Job או ה-DB. ה-Persistent Volume מבטיח שמידע לא יאבד.

11. אבטחת מידע בסיסית (Security Basics)

-
- מסד הנתונים והשירותים החיצוניים אינם כוללים הרשאות (Credentials) מקודדות קשיח (Hard-coded) בקוד הפיתוח.
 - נתוני גישה (Secrets, Usernames, Passwords, API Keys) לא יועלו למערכת ניהול התצורה (Git).
 - שימוש ב-Kubernetes Secrets או משתני סביבה (Environment Variables) להזרקת הגדרות רגישות לקונטיינרים בזמן ריצה.
 - הפרדה ברורה בין קוד אפליקטיבי לבין הגדרות תצורה (Configuration).

12. יעדים וקריטריוני קבלה (Target KPIs & Acceptance)

(Criteria

המערכת תיחשב כמוכנה לפריסה (Production-Ready Prototype) כאשר:

1. **Performance KPI**: יעד ביצועי ה-Pipeline מוגדר להסתיים בתוך פחות מ-15 דקות לריצה בודדת (בהינתן סדר גודל של כ-50 נכסים מנוטרים וכ-500 כותרות חדשות ביום).
2. **FinBERT Coverage Target**: יעד כיסוי: לפחות 95% מכותרות החדשות החוקיות והתקינות (Valid Headlines) מקבלות בהצלחה תוצאת סנטימנט מהמודל. כשלונות מתועדים כראוי ואינם מפילים את ה-Pipeline.
3. **Idempotency Confirmed**: הרצה חוזרת של ה-Pipeline על אותו חלון זמן אינה מייצרת רשומות אנליטיות כפולות בטבלאות העובדות (בזכות מנגנוני ה-Upsert).
4. **Resilience Confirmed**: ניתן לבצע Restart לקלאסטר הקוברנטיס המקומי מבלי לאבד רשומות ממסד הנתונים PostgreSQL.